

PDF CHECK MINERU

智慧型 PDF 文件差異比對系統

結合 MinerU + Docling + PyMuPDF 多層解析引擎
四策略平行差異偵測（文字 / 表格 / 像素 / 圖片）
全流程審計追蹤與多格式匯出

FastAPI

React 19

MinerU 3.x

Docling

PyMuPDF

Docker

WebSocket

系統架構總覽 System Architecture

Frontend — 前端介面

- React 19 + TypeScript + Vite 8 建構
- react-pdf 渲染 PDF , 支援縮放 / 平移
- Zustand 輕量狀態管理 (auth, compare)
- DiffOverlay 元件即時繪製差異框
- Tailwind CSS 響應式佈局

Backend — 後端服務

- FastAPI + Uvicorn 非同步 HTTP/WS 伺服器
- 6 組 REST API 路由 + WebSocket 即時推送
- BackgroundTasks 非阻塞 PDF 解析排程
- SQLite 持久化 (專案 / 比對 / 審計 / 清單)
- PBKDF2-HMAC-SHA256 密碼 + JWT 認證

MinerU 微服務

- 獨立 Docker 容器 (Port 18080)
- 深度學習 Layout Analysis 模型
- 繁中 (chinese_cht) 最佳化
- 模型快取 Volume (~5-8 GB)
- Healthcheck 自動恢復

DATA FLOW 資料流

① 上傳

old.pdf + new.pdf
POST /api/compare/upload

② 解析

4 層 Fallback 引擎
平行 MinerU + Docling

③ 差異比對

4 策略平行執行
文字 / 表格 / 像素 / 圖片

④ 審查

WebSocket 即時進度
側邊欄逐項確認

⑤ 匯出

PDF 標註 / Excel
Markdown / 審計紀錄

PDF 解析技術 Multi-Layer Parsing Engine

Layer 1

PyMuPDF (fitz)

永遠首先執行

- 原始 PDF 文字層擷取 (rawdict 格式)
- 字元級 BBox 座標定位
- 影像型 PDF 偵測 (<10 字 / 頁 + ≥70% 圖像)
- 偵測到純圖 → 直接跳至像素比對

Layer 2

MinerU + Docling < 並行

ThreadPoolExecutor 競速

- MinerU : 深度學習版面分析 + 複雜表格 HTML
- Docling : Layout ML + Tesseract OCR
- 雙引擎同時啟動, 先完成者勝出
- 消除 MinerU 300s 逾時瓶頸, 加速 30-50%

Layer 3

pdftotext (Poppler)

備援層

- Layout-preserving 純文字擷取
- 無結構化表格或精確 BBox
- 合成 BBox (逐行估算座標)

Layer 4

Tesseract OCR

最終防線

- pdftoppm 200 DPI 光柵化 → OCR
- 處理完全無文字層的掃描 PDF
- 速度最慢但涵蓋率最高

座標統一：所有層輸出正規化至 PDF 左下原點 (pt = 1/72 inch) | 文字 NFKC 正規化 + 零寬字元移除

差異比對引擎 & 匯出 Diff Engine & Export Pipeline

策略 A：文字差異 Text Diff

信心度 0.85

- SequenceMatcher 逐段落比對
- CJK 逐字 / 英文逐詞 Tokenize
- 字元級 BBox 精準定位
- 自動分類：TEXT / NUMBER / ADDED / DELETED

策略 B：表格差異 Table Diff

信心度 0.80

- Cell-by-Cell DataFrame 比對
- 70% 聚合規則： $\geq 70\%$ 格變更 $\rightarrow$ 整表替換
- 支援 MinerU HTML rowspan/colspan
- 精確到儲存格座標的差異標記

策略 C：像素差異 Pixel Diff

信心度 0.95

- 二階段 DPI：72 快篩 $\rightarrow$ 200 精準分析
- 灰階絕對差值 + 形態學膨脹合併
- $NCC > 0.98$ 位移偵測 $\rightarrow$ 自動排除
- 連通元件標記 + 面積過濾 ($< 200px^2$ 略過)

策略 D：圖片差異 Image Diff

信心度 0.85

- PyMuPDF 提取嵌入圖片
- $IoU \geq 0.8$ 位置配對同一圖片
- pHash 感知雜湊 Hamming 距離比對
- 略過背景圖 ($\geq 80\%$ 頁面面積)

後處理

Union-Find 合併鄰近差異 (50pt) $\rightarrow$ BBox 巢狀去重 $\rightarrow$ 依 (頁, Y 座標) 排序 $\rightarrow$ d001, d002... 編號

匯出格式

PDF 標註

Excel

Markdown

📋 Checklist 自動匹配 | 審計追蹤 (reviewer, timestamp, action) | 📡 WebSocket 即時進度回傳